

LEMBAR KERJA SISWA (LKS)

Naïve Bayes untuk Kategorikal

Mata Kuliah: Kecerdasan Artificial

Tujuan Pembelajaran

Setelah menyelesaikan LKS ini, mahasiswa mampu:

1. Memahami konsep probabilitas prior dan probabilitas bersyarat.
2. Menghitung *Conditional Probability Table (CPT)* dari data training.
3. Melakukan prediksi manual menggunakan algoritma *Naive Bayes*.
4. Memahami masalah *zero probability*.
5. Menggunakan *Laplace smoothing* untuk mengatasi *zero probability*.

BAGIAN 1 — Memahami Prior dan Likelihood

Studi Kasus: Play Tennis

Sebuah dataset digunakan untuk memprediksi apakah seseorang akan bermain tenis berdasarkan kondisi cuaca.

No	Outlook	Temperature	Humidity	Wind	Play Tennis
1	Sunny	Hot	High	Weak	No
2	Sunny	Hot	High	Strong	No
3	Overcast	Hot	High	Weak	Yes
4	Rain	Mild	High	Weak	Yes
5	Rain	Cool	Normal	Weak	Yes
6	Rain	Cool	Normal	Strong	No
7	Overcast	Cool	Normal	Strong	Yes
8	Sunny	Mild	High	Weak	No
9	Sunny	Cool	Normal	Weak	Yes
10	Rain	Mild	Normal	Weak	Yes
11	Sunny	Mild	Normal	Strong	Yes
12	Overcast	Mild	High	Strong	Yes
13	Overcast	Hot	Normal	Weak	Yes
14	Rain	Mild	High	Strong	No

Aktivitas 1 — Menghitung Prior Probability

Pertanyaan Pengamatan

1. Berapa jumlah data keseluruhan?

Jawaban: 14 data

2. Berapa jumlah data dengan class **Yes**?

Jawaban: 9 data (Yes)

3. Berapa jumlah data dengan class **No**?

Jawaban: 5 data (No)

Hitung Probabilitas Prior

$$P(Yes) = \frac{\text{Jumlah Yes}}{\text{Total Data}}$$

Jawaban: $P(Yes)=9/14=0.6429$

$$P(Yes) = 9/14 = 0.6429$$

$$P(No) = \frac{\text{Jumlah No}}{\text{Total Data}}$$

Jawaban: $P(No)=5/14=0.3571$

$$P(No) = 5/14 = 0.3571$$

Aktivitas 2 — Menghitung Likelihood

Feature: Outlook

Lengkapi tabel berikut.

Outlook	Count pada Yes	P(Outlook Yes)	Count pada No	P(Outlook No)
Sunny	2	2/9	3	3/5
Overcast	4	4/9	0	0/5 = 0
Rain	3	3/9 = 1/3	2	2/5

Refleksi

1. Nilai Outlook apa yang paling sering muncul pada class Yes?

Jawaban: Overcast (4 dari 9 kasus Yes)

2. Nilai Outlook apa yang paling sering muncul pada class No?

Jawaban: Sunny (3 dari 5 kasus No)

3. Menurut Anda, apakah Outlook cukup membantu untuk menentukan keputusan bermain tenis?

Jawaban: Ya, cukup membantu karena distribusi Outlook pada Yes dan No berbeda jelas.

BAGIAN 2 — Formula dan Perhitungan Lengkap

Formula Naive Bayes

$$P(C | X) \propto P(C) \times P(x_1 | C) \times P(x_2 | C) \times \dots \times P(x_n | C)$$

Keterangan:

- $P(C)$ = prior probability class
 - $P(x_i | C)$ = likelihood feature terhadap class
 - X = data baru yang ingin diprediksi
-

Aktivitas 3 — Lengkapi Conditional Probability Table (CPT)

Feature: Temperature

Temperature	P(Temperature Yes)	P(Temperature No)
Hot	2/9	2/5
Mild	4/9	2/5
Cool	3/9 = 1/3	1/5

Feature: Humidity

Humidity	P(Humidity Yes)	P(Humidity No)
High	3/9 = 1/3	4/5
Normal	6/9 = 2/3	1/5

Feature: Wind

Wind	P(Wind Yes)	P(Wind No)
Weak	6/9 = 2/3	2/5
Strong	3/9 = 1/3	3/5

Aktivitas 4 — Prediksi Manual

Diberikan data baru:

$$X = (Sunny, Cool, Normal, Strong)$$

Langkah 1 — Hitung Probabilitas untuk Class Yes

$$P(Yes|X) \propto P(Yes) \times P(Sunny|Yes) \times P(Cool|Yes) \times P(Normal|Yes) \times P(Strong|Yes)$$

Isi nilai: $P(Yes|X) \propto (9/14) * (2/9) * (3/9) * (6/9) * (3/9)$

$$P(Yes|X) \propto (9/14) * (2/9) * (3/9) * (6/9) * (3/9) = 0.01058$$

Hasil: $P(Yes|X) \approx 0.01058$

$$P(Yes|X) = 0.01058$$

Langkah 2 — Hitung Probabilitas untuk Class No

$$P(\text{No}|X) \propto P(\text{No}) \times P(\text{Sunny}|\text{No}) \times P(\text{Cool}|\text{No}) \times P(\text{Normal}|\text{No}) \times P(\text{Strong}|\text{No})$$

Isi nilai: $P(\text{No}|X) \propto (5/14) * (3/5) * (1/5) * (1/5) * (3/5)$

$$P(\text{No}|X) \propto (5/14) * (3/5) * (1/5) * (1/5) * (3/5) = 0.00514$$

Hasil: $P(\text{No}|X) \approx 0.00514$

$$P(\text{No}|X) = 0.00514$$

Langkah 3 — Tentukan Prediksi

Jika:

$$P(\text{Yes}|X) > P(\text{No}|X)$$

maka class prediksi adalah:

Jawaban: Karena $P(\text{Yes}|X) > P(\text{No}|X)$, prediksi class adalah Yes.

BAGIAN 3 — Laplace Smoothing

Masalah Zero Probability

Perhatikan contoh berikut:

Misalkan terdapat kondisi data baru:

$$\text{Temperature} = \text{Cold}$$

Namun pada data training, nilai tersebut tidak pernah muncul pada class tertentu.

Akibatnya:

$$P(Cold|Yes) = 0$$

Karena Naive Bayes mengalikan semua probabilitas, maka hasil akhir juga menjadi **0**.

Solusi: Laplace Smoothing

$$P(x_i | C) = \frac{\text{count}(x_i, C) + 1}{\text{count}(C) + |x_i \text{ values}|}$$

Keterangan:

- $\text{count}(x_i, C)$ = jumlah kemunculan feature pada class
 - $\text{count}(C)$ = jumlah data pada class
 - $|x_i \text{ values}|$ = jumlah kemungkinan nilai feature
-

Aktivitas 5 — Perbandingan Tanpa dan Dengan Smoothing

Contoh Kasus

Feature **Temperature** memiliki 3 kemungkinan nilai:

- Hot
- Mild
- Cool

Misalkan:

- $\text{count}(C = No) = 5$
 - $\text{count}(Hot, No) = 0$
-

Tanpa Smoothing

$$P(Hot|No) = \frac{0}{5} = 0$$

Dengan Laplace Smoothing

$$P(Hot|No) = \frac{0 + 1}{5 + 3}$$

Hitung hasilnya:

Jawaban: $P(Hot|No) = (0+1)/(5+3) = 1/8 = 0.125$

Aktivitas 6 — Prediksi dengan Smoothing

Diberikan data baru:

$$X = (Overcast, Hot, Normal, Weak)$$

Hitung ulang probabilitas menggunakan Laplace smoothing.

Perhitungan Class Yes

$$P(Yes|X) \propto (9/14) * (5/12) * (3/12) * (7/11) * (7/11)$$

$$P(Yes|X) \approx 0.02712$$

(kelas Yes lebih besar)

Perhitungan Class No

$$P(No|X) \propto (5/14) * (1/8) * (3/8) * (2/7) * (3/7)$$

$$P(No|X) \approx 0.00205$$

Prediksi akhir dengan smoothing: Yes

Kesimpulan

Mengapa smoothing penting?

Jawaban: Smoothing mencegah probabilitas 0 sehingga model tetap bisa membandingkan semua class secara adil.

Tanpa smoothing, satu feature bernilai 0 akan membuat seluruh hasil perkalian menjadi 0.

BAGIAN 4 — Prediksi Mandiri

Studi Kasus: Smartphone Recommendation

Tujuan: Memprediksi apakah sebuah smartphone direkomendasikan atau tidak.

Dataset Training

No	Battery	RAM	Storage	Camera	Price	Recommend
1	High	8GB	128GB	16MP	Expensive	Yes
2	Medium	4GB	64GB	12MP	Medium	Yes
3	Low	2GB	32GB	8MP	Cheap	No
4	High	8GB	128GB	16MP	Medium	Yes
5	Medium	4GB	64GB	8MP	Cheap	No
6	High	8GB	64GB	12MP	Expensive	Yes
7	Low	2GB	32GB	8MP	Cheap	No
8	Medium	4GB	128GB	12MP	Medium	Yes
9	High	8GB	128GB	16MP	Expensive	Yes
10	Medium	2GB	32GB	8MP	Cheap	No
11	High	4GB	64GB	12MP	Medium	Yes
12	Low	2GB	64GB	8MP	Cheap	No
13	Medium	8GB	128GB	16MP	Expensive	Yes
14	High	4GB	128GB	12MP	Medium	Yes
15	Low	2GB	32GB	8MP	Cheap	No

Tugas Mandiri

Tugas 1 — Hitung Prior Probability

Hitung: $P(\text{Yes})=9/15=0.6$ dan $P(\text{No})=6/15=0.4$

$$P(\text{Yes}) = 9/15 = 0.6$$

dan

$$P(No) = 6/15 = 0.4$$

Tugas 2 — Lengkapi CPT dengan Laplace Smoothing

Lengkapi conditional probability table untuk seluruh feature:

- Battery
- RAM
- Storage
- Camera
- Price

Feature: Battery

Battery	P(Battery Yes)	P(Battery No)
High	$(6+1)/(9+3)=7/12$	$(0+1)/(6+3)=1/9$
Medium	$(3+1)/(9+3)=4/12=1/3$	$(2+1)/(6+3)=3/9=1/3$
Low	$(0+1)/(9+3)=1/12$	$(4+1)/(6+3)=5/9$

Feature: RAM

RAM	P(RAM Yes)	P(RAM No)
8GB	$(5+1)/(9+3)=6/12=1/2$	$(0+1)/(6+3)=1/9$
4GB	$(4+1)/(9+3)=5/12$	$(1+1)/(6+3)=2/9$
2GB	$(0+1)/(9+3)=1/12$	$(5+1)/(6+3)=6/9=2/3$

Feature: Storage

Storage	P(Storage Yes)	P(Storage No)
128GB	$(6+1)/(9+3)=7/12$	$(0+1)/(6+3)=1/9$
64GB	$(3+1)/(9+3)=4/12=1/3$	$(2+1)/(6+3)=3/9=1/3$
32GB	$(0+1)/(9+3)=1/12$	$(4+1)/(6+3)=5/9$

Feature: Camera

Camera	P(Camera Yes)	P(Camera No)
16MP	$(4+1)/(9+3)=5/12$	$(0+1)/(6+3)=1/9$
12MP	$(5+1)/(9+3)=6/12=1/2$	$(0+1)/(6+3)=1/9$

8MP	$(0+1)/(9+3)=1/12$	$(6+1)/(6+3)=7/9$
-----	--------------------	-------------------

Feature: Price

Price	P(Price Yes)	P(Price No)
Expensive	$(4+1)/(9+3)=5/12$	$(0+1)/(6+3)=1/9$
Medium	$(5+1)/(9+3)=6/12=1/2$	$(0+1)/(6+3)=1/9$
Cheap	$(0+1)/(9+3)=1/12$	$(6+1)/(6+3)=7/9$

Tugas 3 — Prediksi Data Baru dengan Laplace Smoothing

Data Uji 1

$$X_1 = (\text{Medium}, 4GB, 64GB, 8MP, \text{Medium})$$

Langkah perhitungan dan Prediksi Akhir: $P(\text{Yes}|X_1) \approx 0.001157$ dan $P(\text{No}|X_1) \approx 0.000854$, jadi prediksi $X_1 = \text{Yes}$.

Data Uji 2

$$X_2 = (\text{Low}, 4GB, 128GB, 8MP, \text{Expensive})$$

Langkah perhitungan dan Prediksi Akhir: $P(\text{Yes}|X_2) \approx 0.000422$ dan $P(\text{No}|X_2) \approx 0.000474$, jadi prediksi $X_2 = \text{No}$.

Refleksi

1. Menurut Anda, feature mana yang paling menentukan keputusan rekomendasi smartphone?

Jawaban: Feature Price sangat menentukan karena distribusinya paling kontras antara class Yes dan No.

2. Mengapa Naive Bayes masih bisa bekerja dengan baik meskipun asumsi *independence* antar feature tidak selalu benar?

Jawaban: Karena Naive Bayes mengestimasi probabilitas per feature secara sederhana, sehingga tetap robust meski asumsi independensi tidak sempurna.

3. Apa kelebihan utama Naive Bayes dibanding metode lain?

Jawaban: Kelebihan utamanya adalah sederhana, cepat dilatih, dan tetap efektif untuk data kategorikal dengan data relatif sedikit.
